

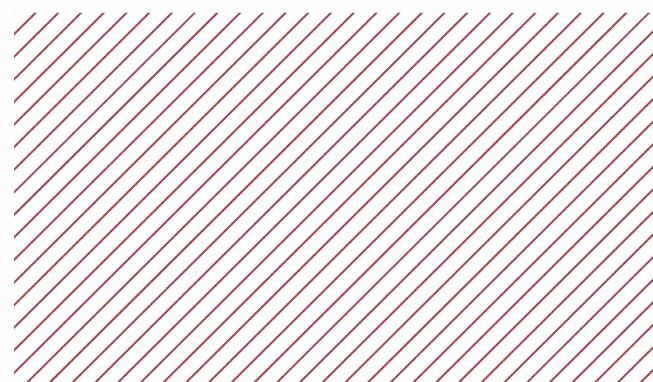
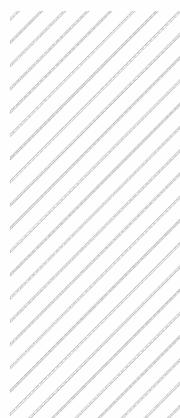
академия
больших
данных

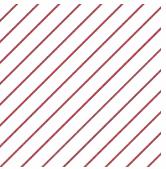


Введение в глубокое обучение Нейрон

Иван Карпухин

Ведущий программист-исследователь в
команде машинного зрения





Вопрос 1

Приходилось ли вам использовать машинное обучение?



Вопрос 2

Приходилось ли вам использовать нейронные сети?

Введение

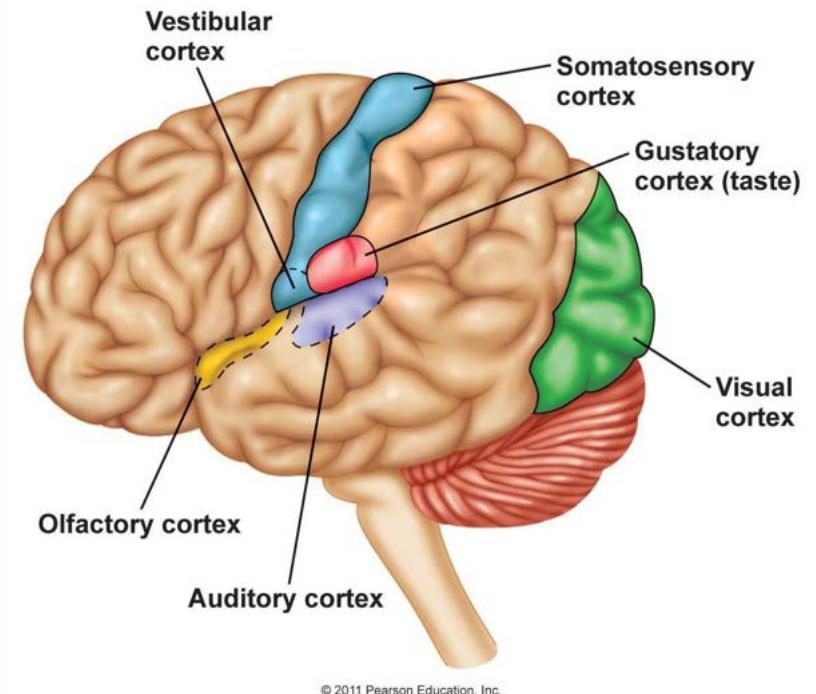


Deep learning

Традиционно цель DL - воспроизвести мыслительные процессы человека.

Современный DL решает многие задачи Machine Learning:

- генерация изображений, звуков, текстов
- принятие решений
- классификация
- регрессия
- кластеризация
- уменьшение размерности
- ...



История

1958: Перцептрон Розенблатта

1974: Backpropagation

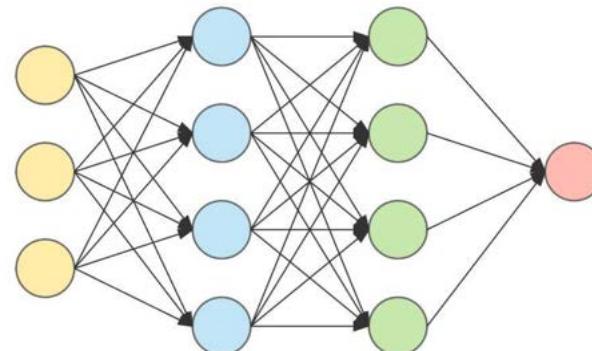
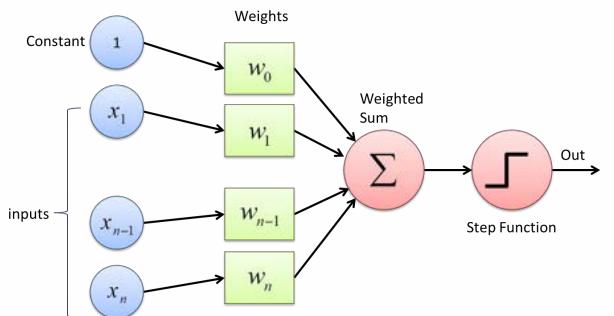
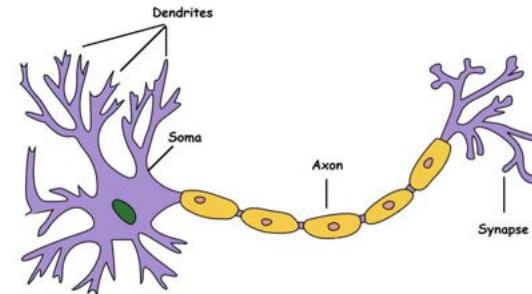
1985: Машины Больцмана

1986: RNN

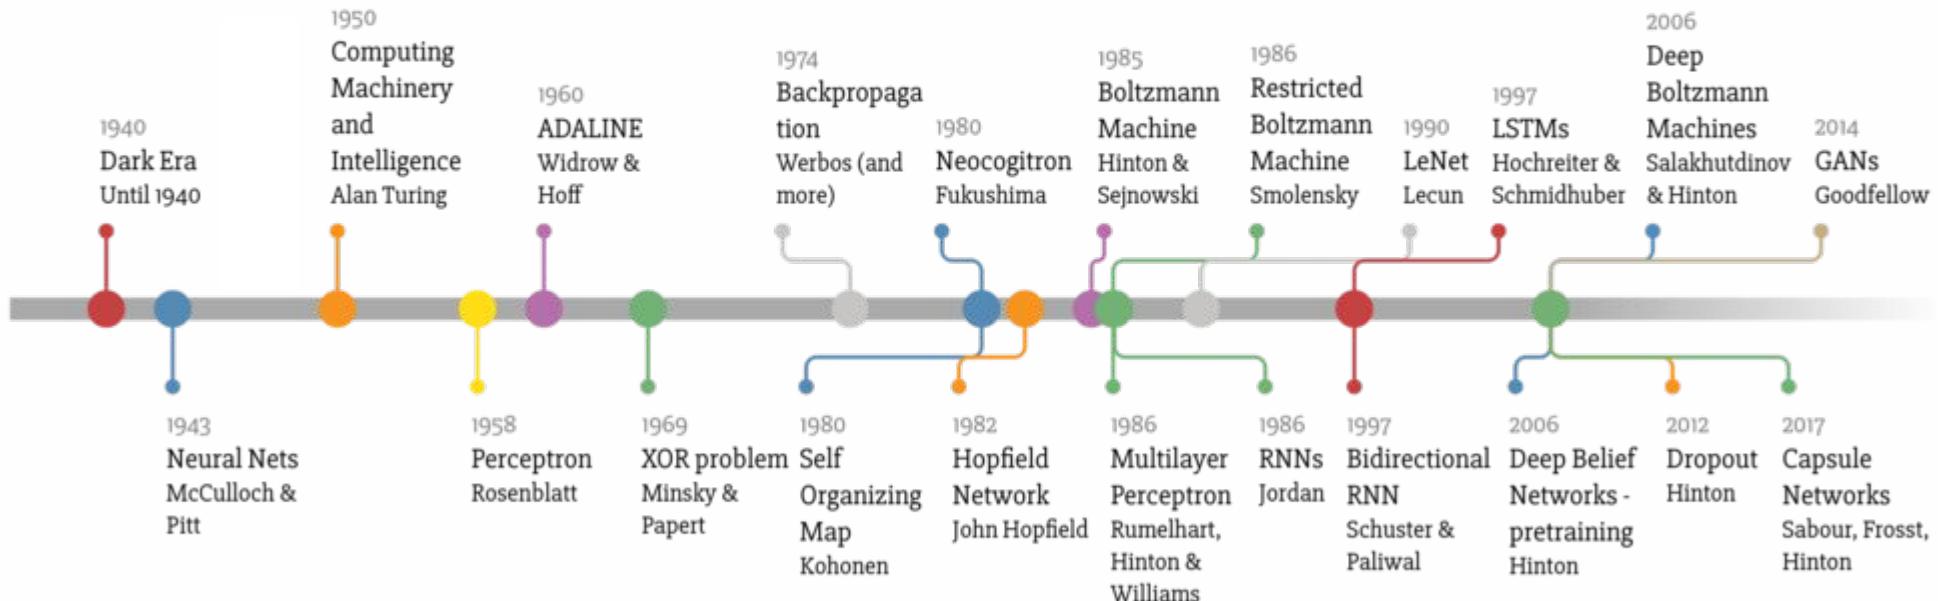
2012: Dropout

2014: GANs

2015: Batchnorm



История



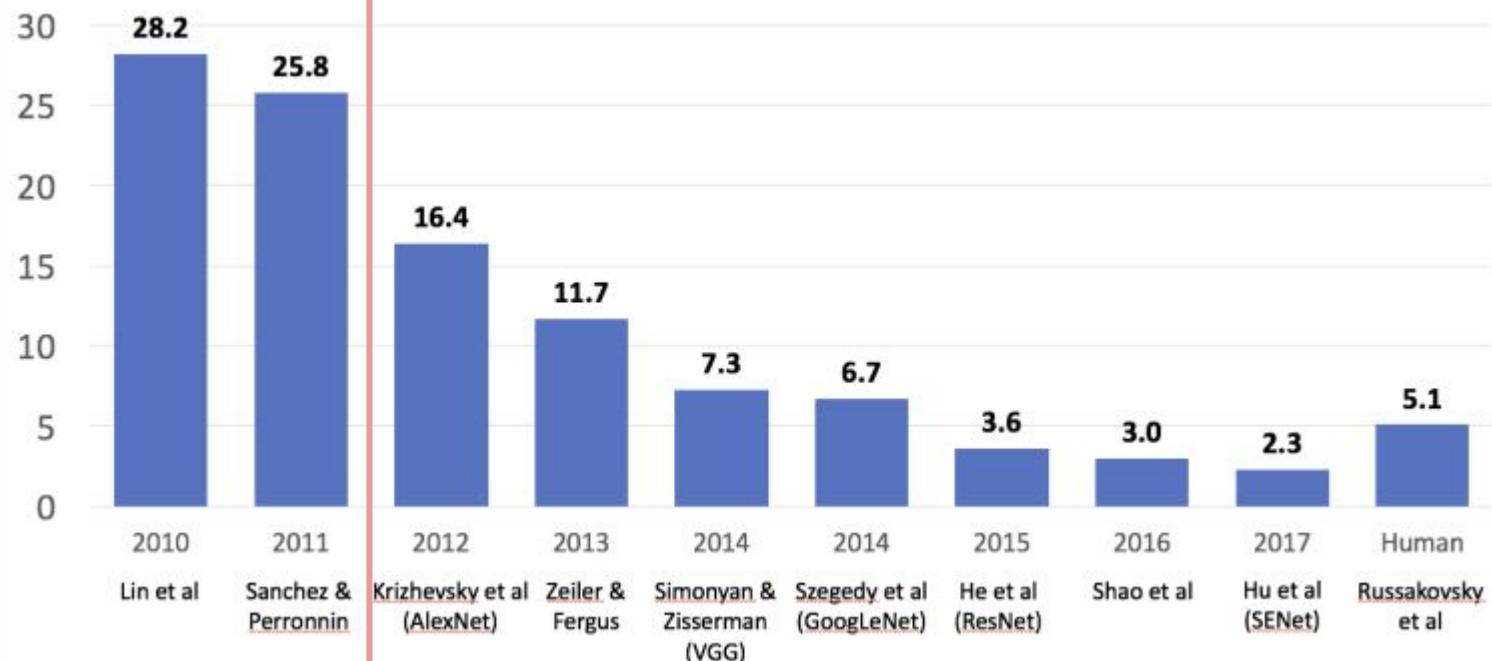
Made by Favio Vázquez

<https://towardsdatascience.com/rosenblatts-perceptron-the-very-first-neural-network-37a3ec09038a>

История

Imagenet image classification challenge

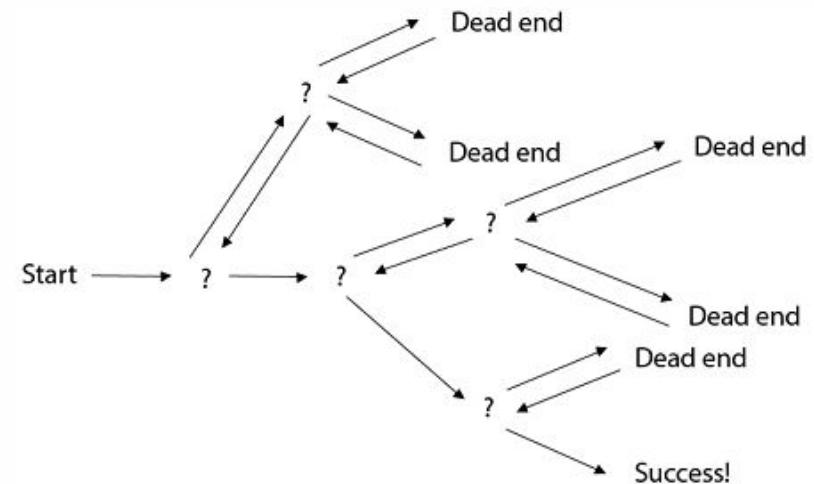
Deep learning

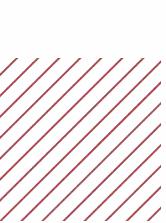


Deep Learning: история термина

“Learning while searching in constraint-satisfaction-problems”. Rina Dechter. 1986.

- Впервые использован термин “deep learning”
- Не имеет отношения к нейронным сетям
- Задача поиска значений переменных с ограничениями
- Depth-first search + constraint learning





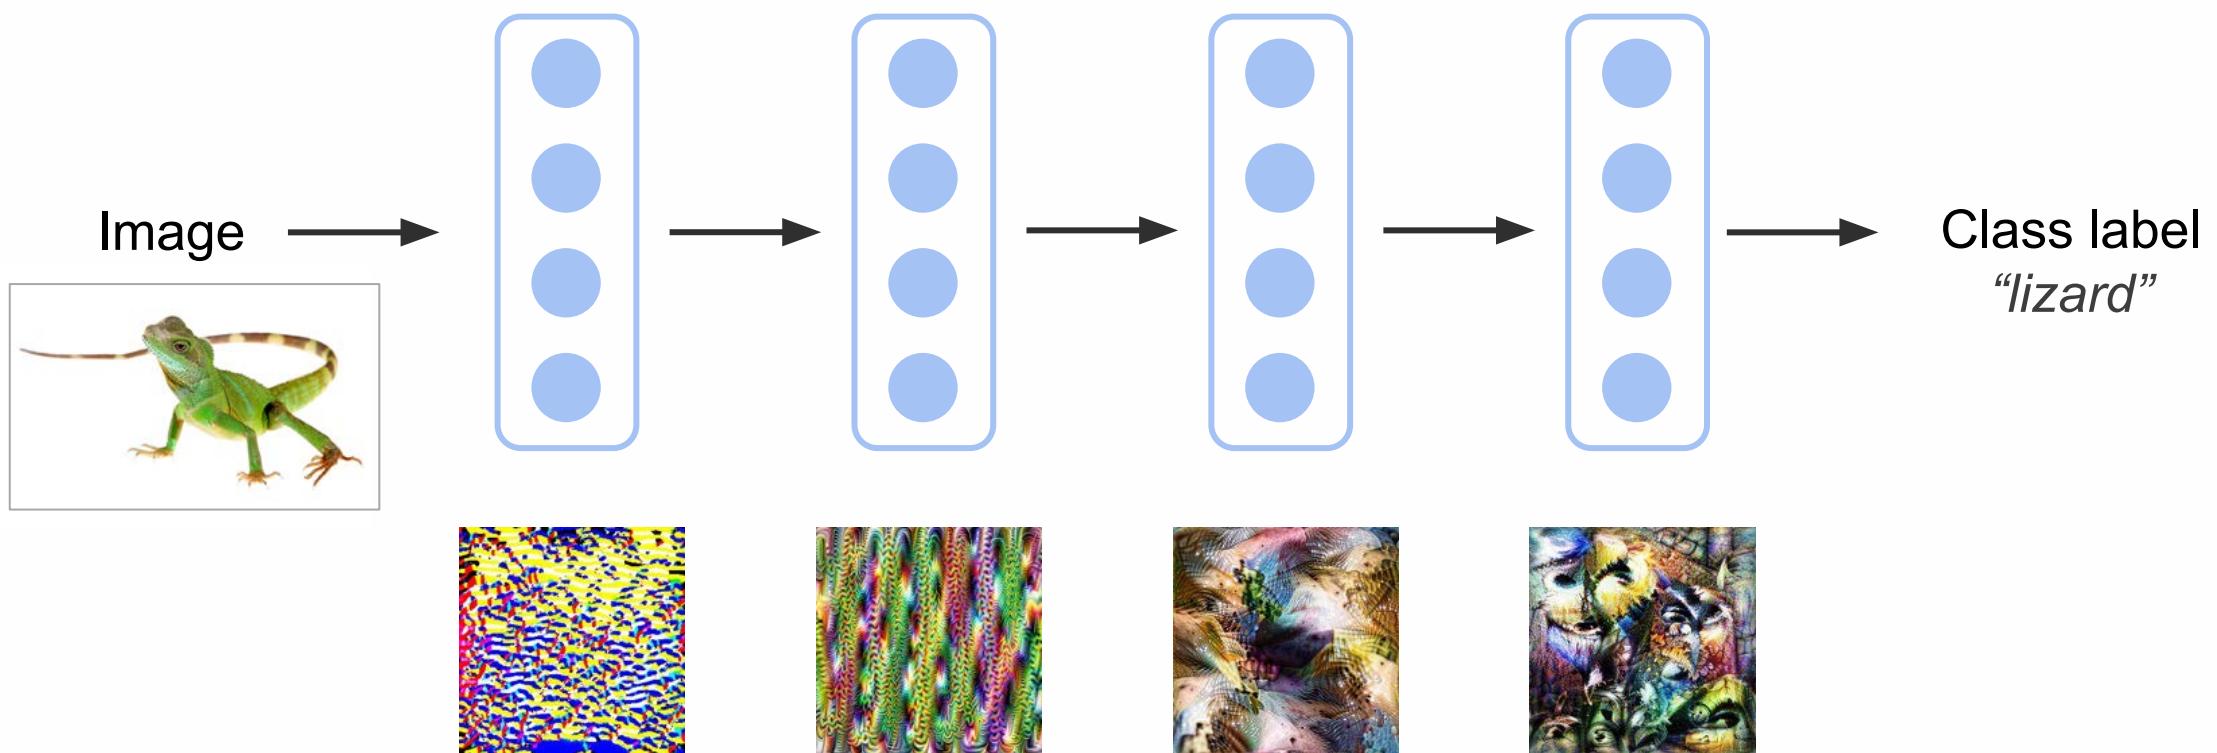
Deep Learning: история термина

“Multi-Valued and Universal Binary Neurons: Theory, Learning and Applications”.
Igor Aizenberg. 2000.

*“1960-s: The extensive development of the threshold logic, initiated by previous results in perceptron theory. A **deep learning** of the features of threshold Boolean functions, as one of the most important objects considered in the theory of perceptrons and neural networks.”*

- Deep learning - обучение иерархии признаков при помощи нейронных сетей
- Первые успешные попытки -

Deep Learning: история термина



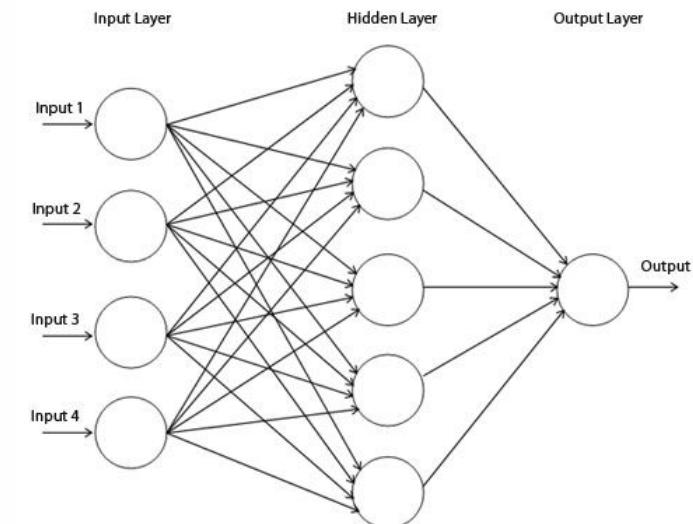
Изображения с сайта <https://microscope.openai.com>

Deep VS shallow

Универсальная теорема аппроксимации утверждает, что одного скрытого слоя достаточно, при условии, что он достаточно велик.

На практике глубокие сети обобщают лучше

Можно провести аналогии с динамическим программированием: предпосчитанные признаки экономят вычисления.



Области науки и технологии

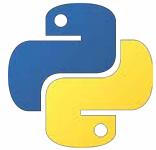
Математика

- Линейная алгебра (векторы, матрицы, линейные отображения)
- Анализ (непрерывность, производная)
- Теория информации (перекрёстная энтропия, взаимная информация)
- Оптимизация (градиентный спуск)

Инженерия

- Обработка сигналов (фильтры, свертки, кодирование)
- Программирование (больше работы с библиотеками, меньше алгоритмы)

Инструменты



Python: основной язык

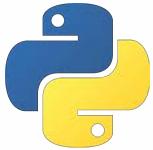
- Популярный язык для CV и DL
- Множество библиотек
- Легко читается

```
def crop_image(image, bbox):
    """Crop image to bounding box.

    Args:
        image: Image in WHC format.
        bbox: Bounding box in XYWHA format (A for angle).

    Returns:
        Crop in WHC format.
    """
    if image.shape[-1] > 4:
        raise ValueError("Image channels should be at last dimension")
    src_points = get_bbox_points(bbox).astype("float32")
    dst_points = np.array([[0, bbox[BBOX_HEIGHT] - 1],
                          [0, 0],
                          [bbox[BBOX_WIDTH] - 1, 0],
                          [bbox[BBOX_WIDTH] - 1, bbox[BBOX_HEIGHT] - 1
                           dtype="float32"])
    M = cv2.getPerspectiveTransform(src_points, dst_points)
    crop = cv2.warpPerspective(image, M, (int(bbox[BBOX_WIDTH]), int(bb
    return crop
```

Инструменты



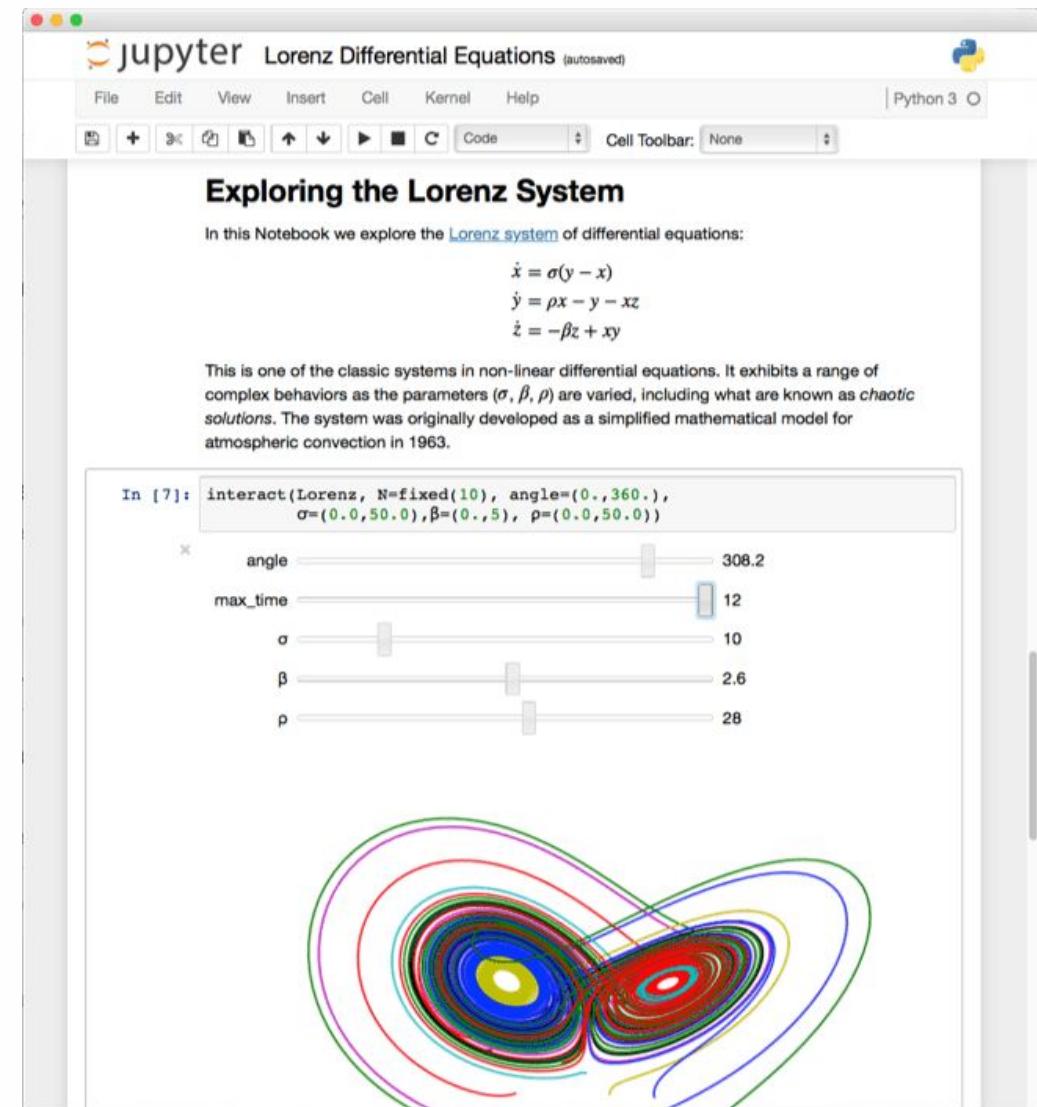
Python: основной язык

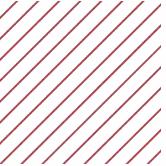
- Популярный язык для CV и DL
- Множество библиотек
- Легко читается



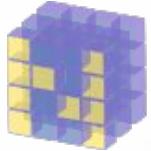
Jupyter: среда для прототипирования

- Документация и код
- Демонстрации
- Быстрая разработка





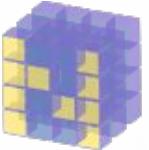
Инструменты



NumPy: линейная алгебра

- Матричные операции
- Работа с многомерными массивами (тензорами)

Инструменты



NumPy: линейная алгебра

- Матричные операции
- Работа с многомерными массивами (тензорами)

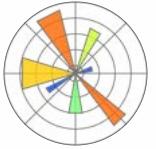


OpenCV: работа с изображениями

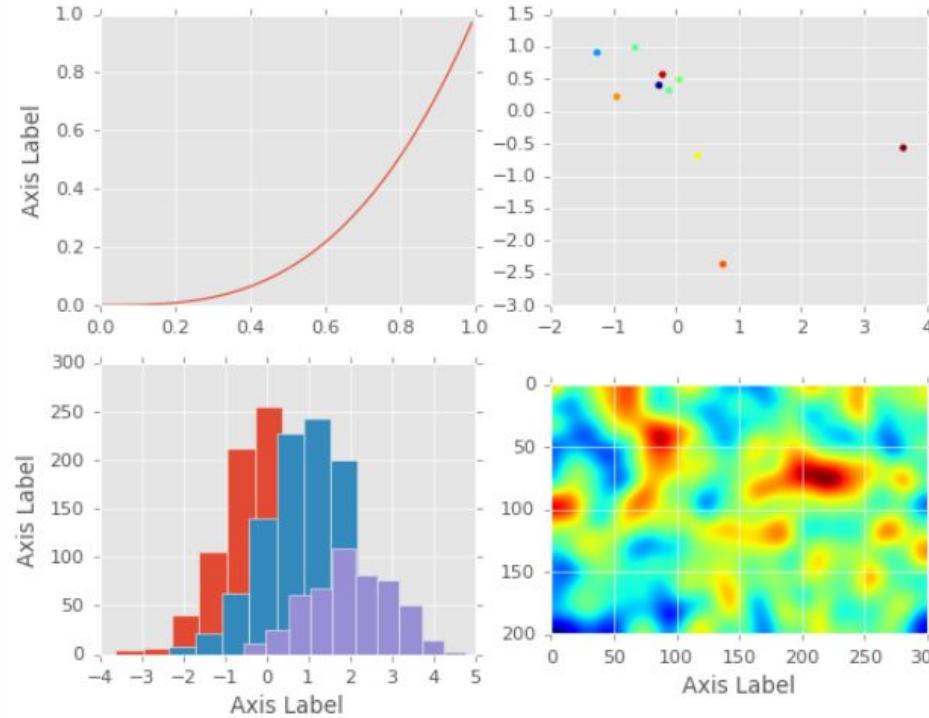
- Чтение и запись изображений
- Преобразования цвета
- Повороты, масштабирование, деформация, фильтры
- Алгоритмы



Инструменты



Matplotlib: визуализация

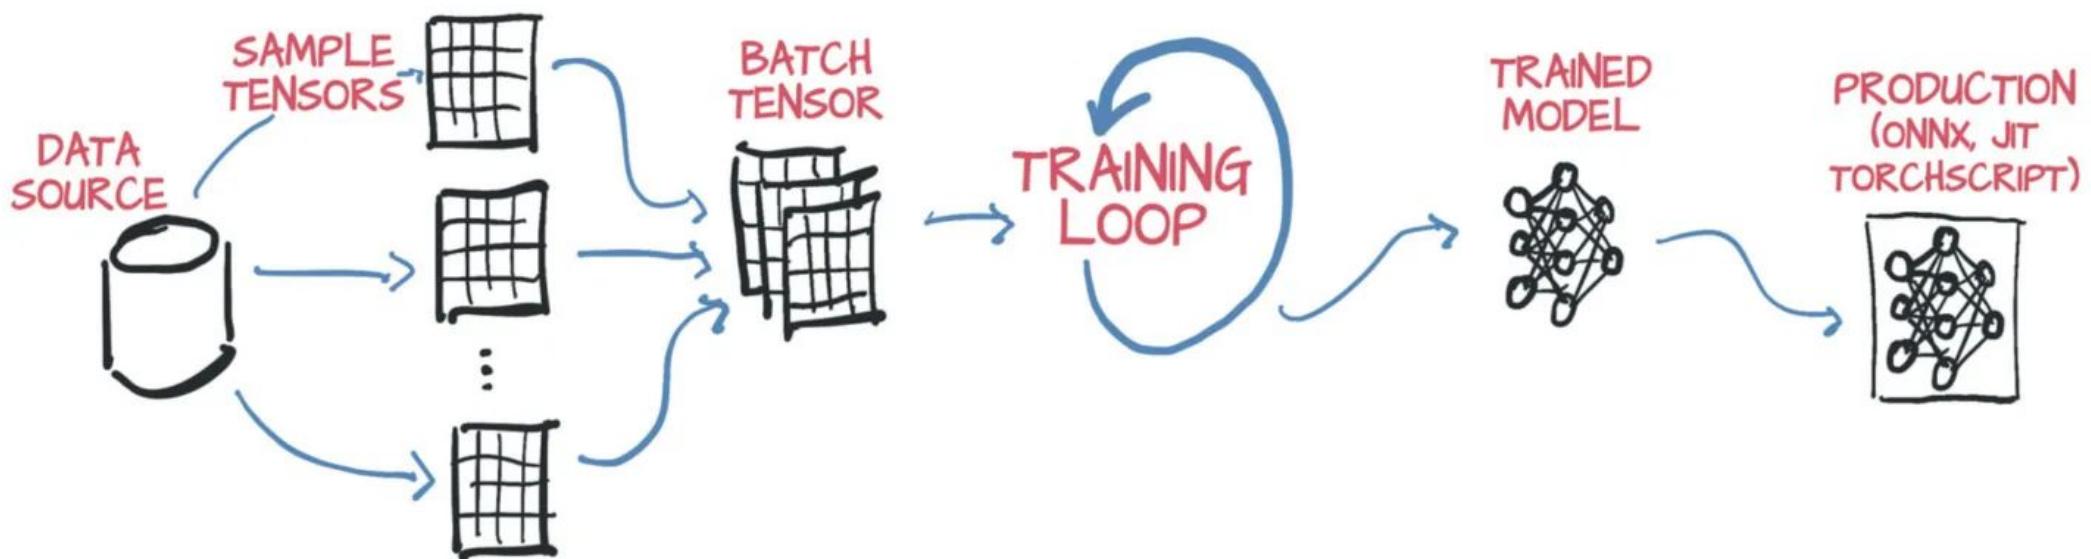


Инструменты

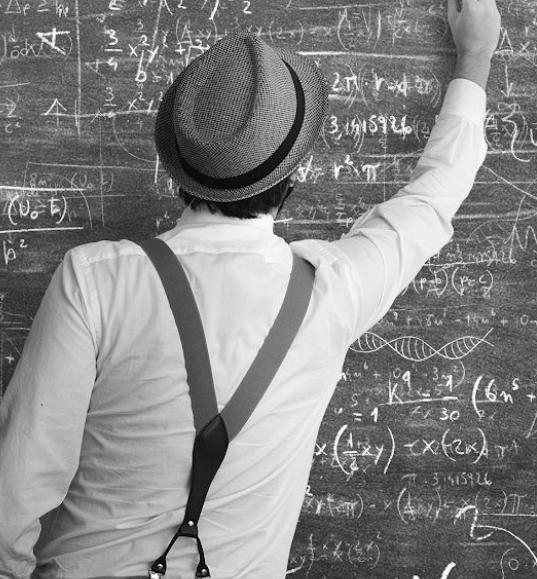


PyTorch: нейронные сети

- Популярный фреймворк для DL
- Множество реализованных сетей и блоков
- Оптимизация на GPU



Kypc



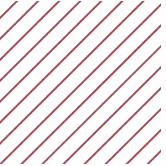


План курса

Цель - основные архитектуры и их обучение в PyTorch

Занятия:

1. DL введение, обучение нейрона. Семинар: Логистическая регрессия на Numpy
2. FC-сеть, backprop. Семинар: FC-сеть на Numpy
3. Оптимизация, регуляризация. Семинар: PyTorch.
4. Сверточные сети. Семинар: PyTorch CNN.
5. ML pipeline. Семинар: PyTorch Lightning, Optuna.
6. RNN. Семинар: PyTorch RNN.



Оценки

Точно будет тест в конце

Возможно, будет промежуточный тест

По результатам тестов будут выставлены оценки за DL курс

Преподаватели



Радослав Нейчев

Автор курсов по ML/DL в МФТИ,
Harbour.Space, и академии Mail.ru



Даниил Лысухин

Программист-исследователь
в команде машинного зрения



Андрей Бояров

Ведущий программист-исследователь
в команде машинного зрения



Иван Карпухин

Ведущий программист-исследователь
в команде машинного зрения



Фёдор Киташов

Программист-исследователь
в команде машинного зрения



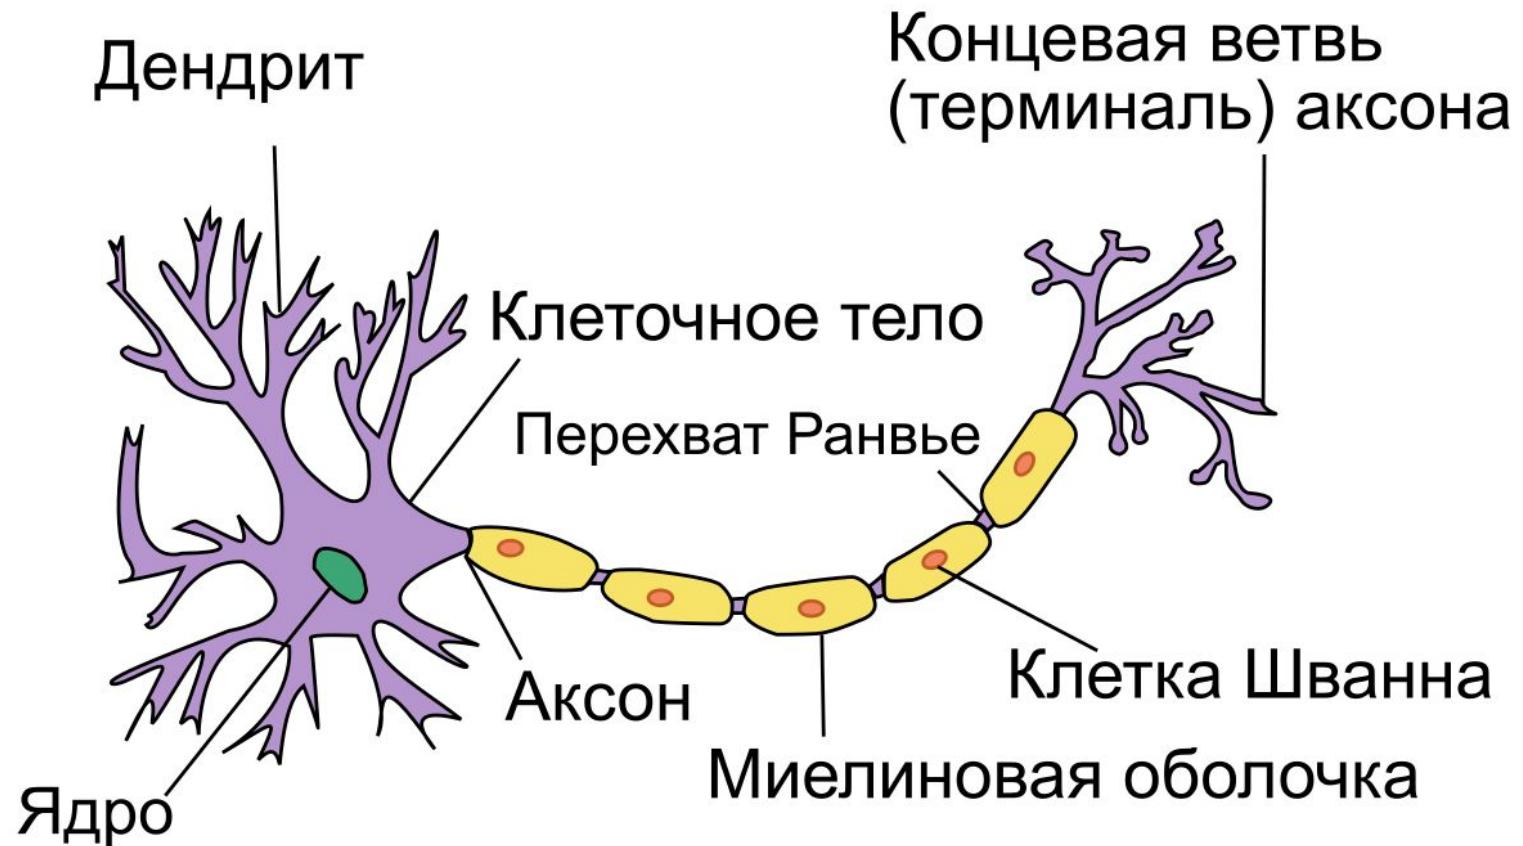
Борис Лесцов

Программист-исследователь
в команде машинного зрения

0 0 1 1 0 1
1 0 1 0 1 1
0 00 0111 1 10 101

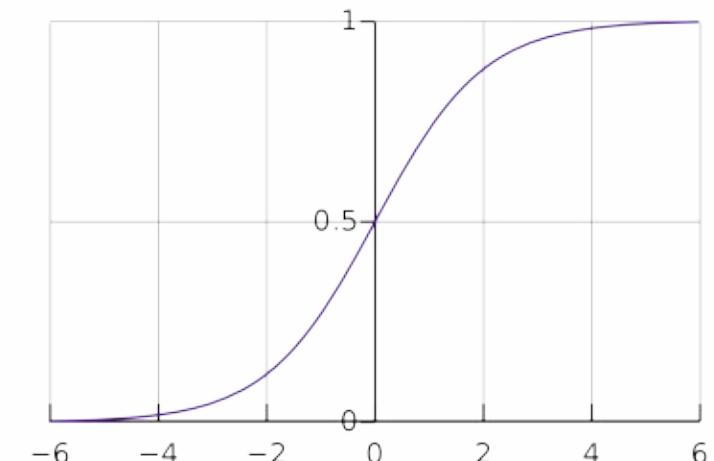
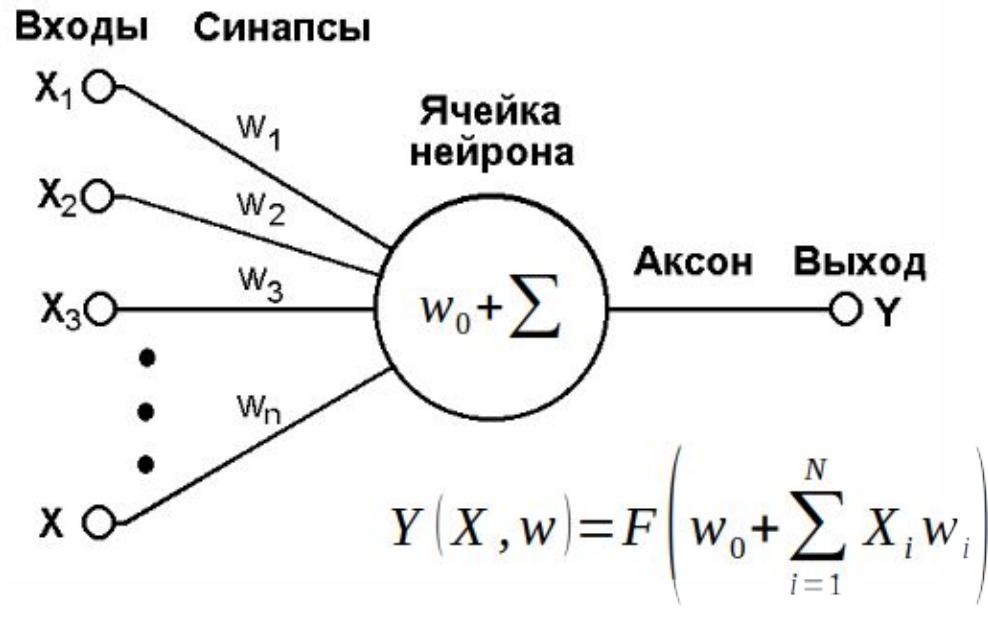
Нейрон

Нейрон в биологии



Модель нейрона

Если функция активации – сигмоида, то получается модель, похожая на логистическую регрессию.



$$F(S) = \frac{1}{1 + e^{-S}}$$

* Rosenblatt F. The perceptron, a perceiving and recognizing automaton Project Para. 1957.

Логистическая функция активации

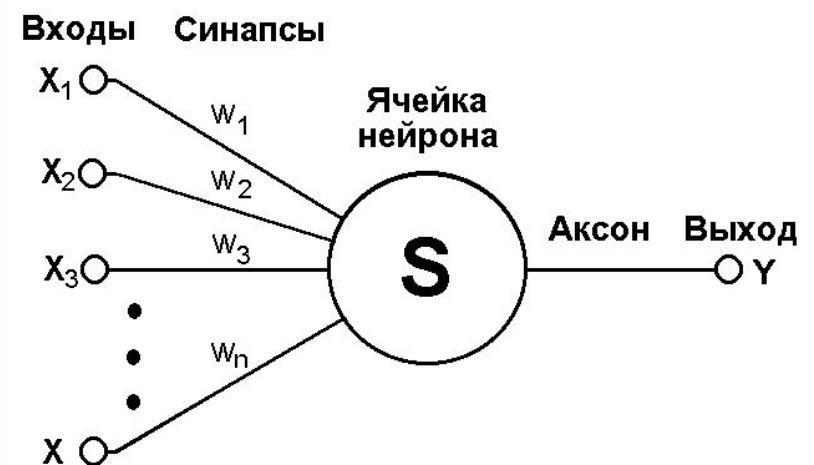
$$P(L = 1|X) = Y(X, w) = \sigma(r) = \frac{1}{1 + e^{-r}}$$

$$r = w_0 + \sum_{i=1}^N X_i w_i$$

Что такое r ?

$$-r = \log\left(\frac{1}{P} - 1\right) = \log\frac{1 - P}{P}$$

$$r = \log\frac{P}{1 - P}$$



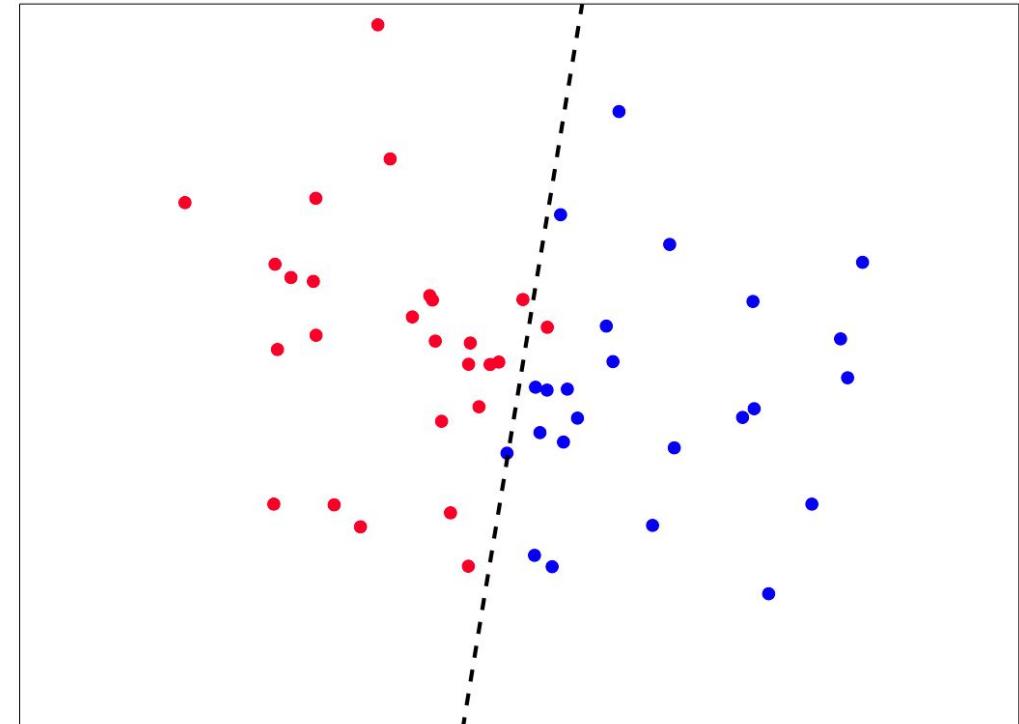
r - логарифм отношения правдоподобий двух гипотез: $L = 1$ и $L = 0$

Бинарная классификация

$$Y(X, w) = F(w_0 + \sum_{i=1}^N X_i w_i)$$

$$P(X, w) = \begin{cases} 1, & Y(X, w) \geq \text{threshold} \\ 0, & Y(X, w) < \text{threshold} \end{cases}$$

Если $F(S)$ монотонна, то разделяющая поверхность - гиперплоскость.



Функция потерь

$$Y(X, w) = F(w_0 + \sum_{i=1}^N X_i w_i)$$

$$P(X, w) = \begin{cases} 1, & Y(X, w) \geq \text{threshold} \\ 0, & Y(X, w) < \text{threshold} \end{cases}$$

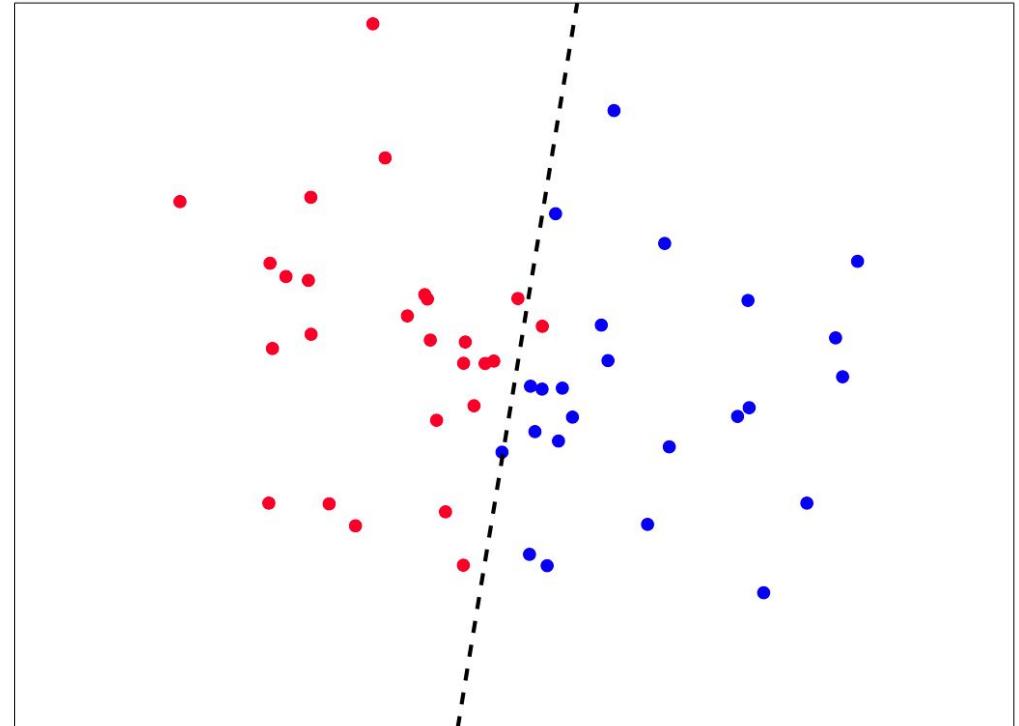
$$\text{Error}(w) = \frac{1}{|X|} \sum_X \text{Error}(X, w)$$

- L2:

$$\text{Error}(X, w) = (Y(X, w) - L(X))^2$$

- Перекрёстная энтропия:

$$\text{Error}(X, w) = \begin{cases} -\log Y(X, w), & L(X) = 1 \\ -\log(1 - Y(X, w)), & L(X) = 0 \end{cases}$$

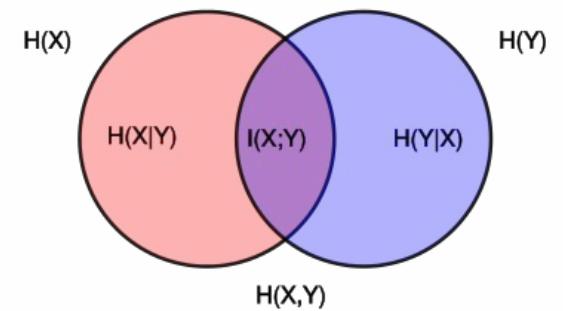
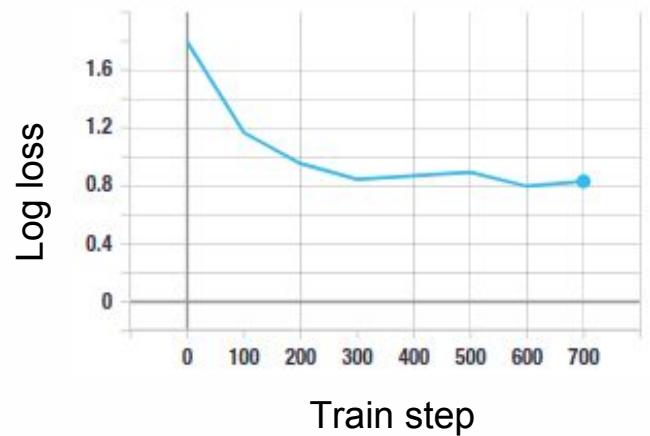


Усреднение перекрёстной энтропии

- На каждом шаге считается перекрестная энтропия $H(p, q)$
- Значения усредняются для нескольких сэмплов

Что отражает итоговый лосс?

$$\begin{aligned} Loss &= - \sum_i P(X_i) \sum_j P(L = j | X_i) \log Q(L = j | X_i) \\ &\geq - \sum_i P(X_i) \sum_j P(L = j | X_i) \log P(L = j | X_i) \\ &= - \sum_i \sum_j P(L = j, X_i) \log \frac{P(L = j, X_i)}{P(X_i)} \\ &= - \sum_i \sum_j P(L = j, X_i) \log P(L = j, X_i) + \sum_i P(X_i) \log P(X_i) \\ &= H(X, L) - H(X) = H(L|X) = H(L) - I(X, L) \end{aligned}$$



Оптимизация

$$Y(X, w) = F(w_0 + \sum_{i=1}^N X_i w_i)$$

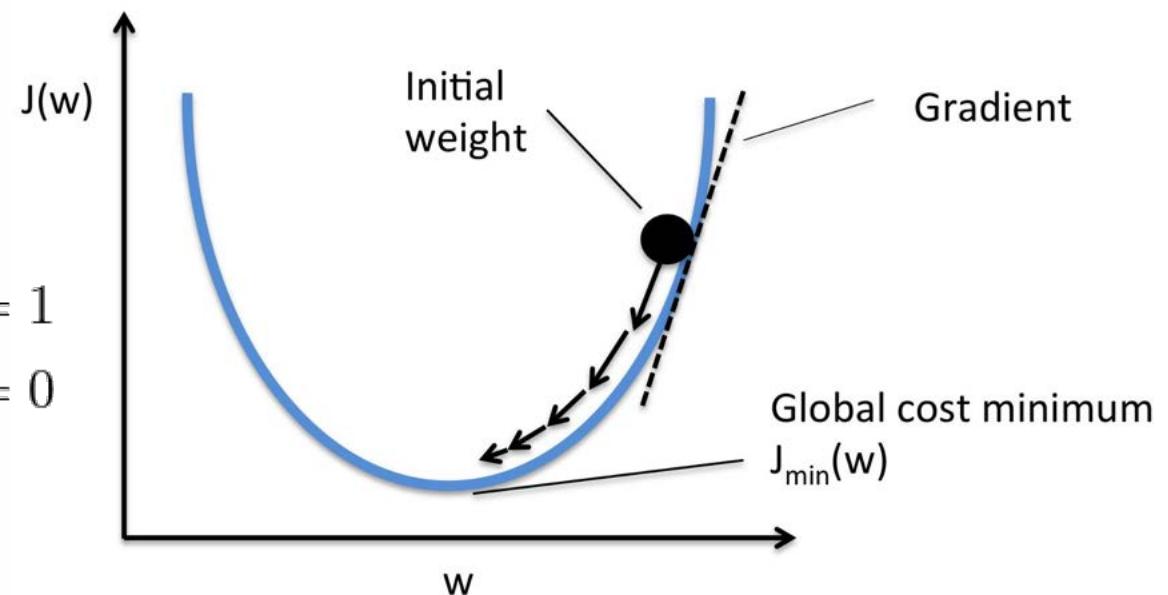
$$Error(w) = \frac{1}{|X|} \sum_X Error(X, w)$$

$$Error(X, w) = \begin{cases} -\log Y(X, w), & L(X) = 1 \\ -\log(1 - Y(X, w)), & L(X) = 0 \end{cases}$$

$$w = \operatorname{argmin} Error(w)$$

Если F дифференцируема:

- Y и $Error$ дифференцируемы
- можно использовать метод градиентного спуска для нахождения вектора весов w



Градиентный спуск

Одномерный случай:

$$f : \mathbb{R} \rightarrow \mathbb{R}$$

$$w = \underset{w}{\operatorname{argmin}} f(w)$$

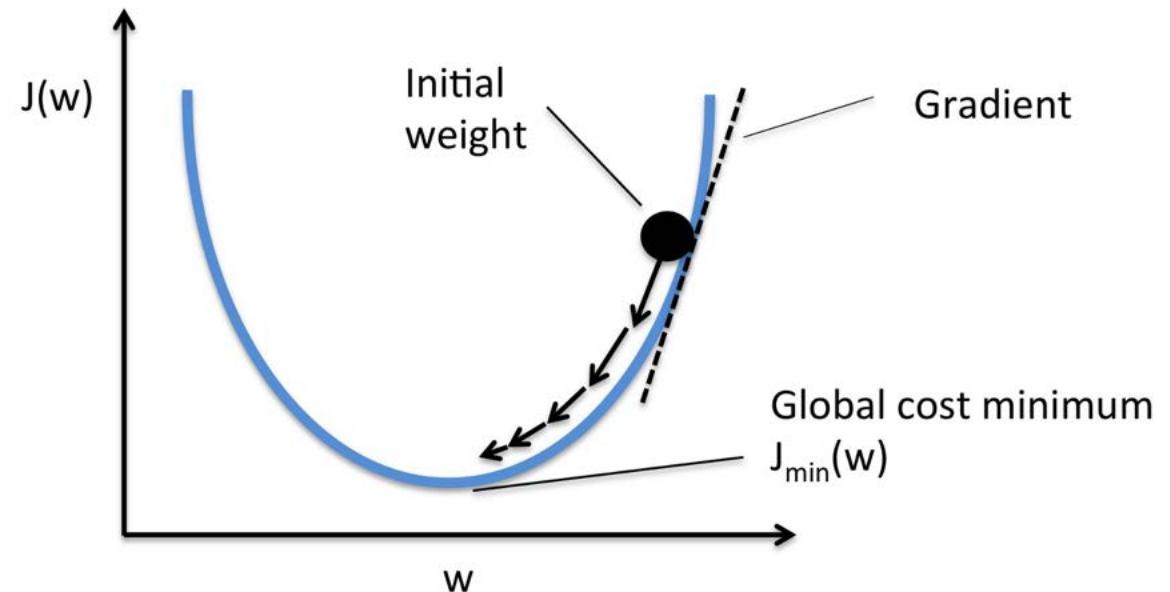
$$w_{i+1} = w_i - \lambda f'(w_i), \forall w_0$$

Многомерный случай:

$$f : \mathbb{R}^N \rightarrow \mathbb{R}$$

$$W = \underset{W}{\operatorname{argmin}} f(W)$$

$$W_{i+1} = W_i - \lambda \nabla f(W_i), \forall W_0$$



Производные Log. reg.

$$Y(X, w) = \sigma(w_0 + \sum_{i=1}^N X_i w_i)$$

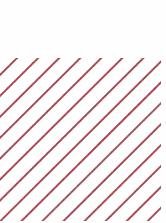
$$Y'_{w_0}(X, w) = \sigma(w_0 + \sum_{i=1}^N X_i w_i)(1 - \sigma(w_0 + \sum_{i=1}^N X_i w_i))$$

$$Y'_{w_i}(X, w) = \sigma(w_0 + \sum_{i=1}^N X_i w_i)(1 - \sigma(w_0 + \sum_{i=1}^N X_i w_i))X_i, i \geq 1$$

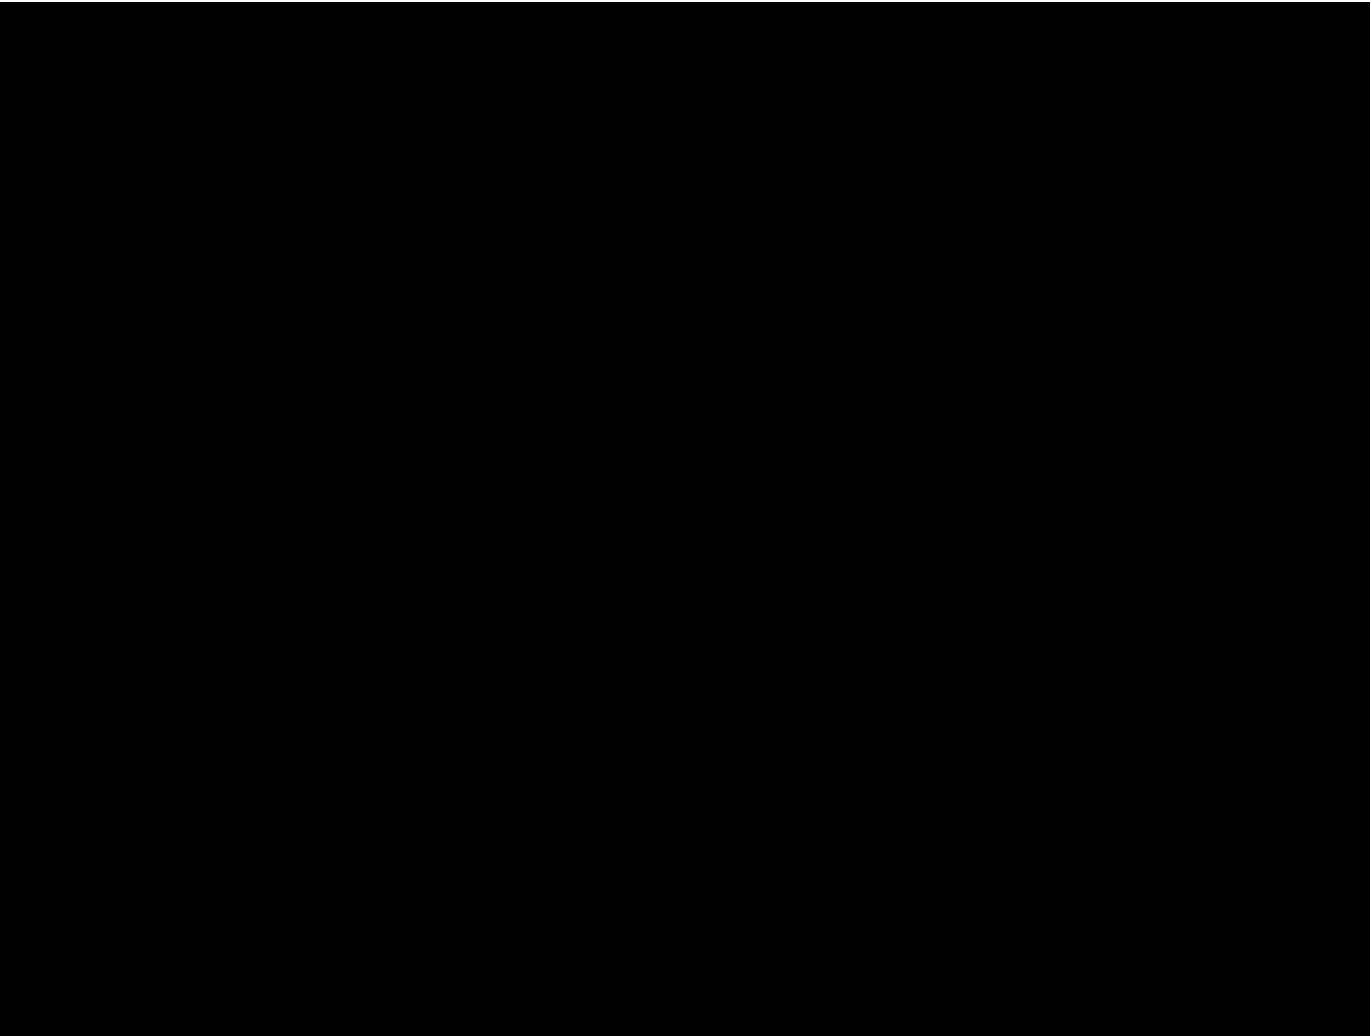
$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

$$\sigma'(x) = \sigma(x)(1 - \sigma(x))$$

$$f(g(x))'_x = f'(g(x))g'(x)$$

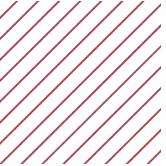


Градиентный спуск



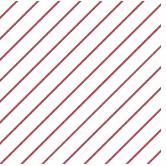
0 0 1 1 0 1
1 0 1 0 1 1
0 00 0111 1 10 101

Резюме



Резюме

- DL около 60 лет
- Переломный момент - 2010-е, когда качество DL моделей обогнало многие традиционные методы ML и появилась масса приложений на базе DL.
- Курс - базовая часть специализированных DL курсов (CV, NLP, Speech)



Резюме

- Нейронные сети – дифференцируемые модели
- Обучение сети – минимизация функции потерь методом градиентного спуска
- Функция потерь для классификации – перекрёстная энтропия
- Усреднённая перекрёстная энтропия – верхняя оценка условной энтропии



В следующий раз...

- Полносвязные сети
- Метод обратного распространения ошибки
- Классификация с множеством классов